

The background is a dark, textured surface. Three paper airplanes are scattered: a yellow one at the top right, a grey one at the middle left, and another grey one at the bottom right. A dashed white line, drawn with chalk, starts from the bottom left, loops around the grey airplane in the middle left, extends upwards towards the yellow airplane, loops around the grey airplane at the bottom right, and ends near the bottom right corner.

Линейные методы классификации

МАКСИМОВСКАЯ
АНАСТАСИЯ

Задача классификации

Задача классификации — задача, в которой имеется множество объектов, разделённых некоторым образом на классы. Задано конечное множество объектов, для которых известно, к каким классам они относятся.

Линейный классификатор — алгоритм классификации, основанный на построении линейной разделяющей поверхности.

Бинарная классификация — это задача классификации элементов заданного множества в две группы.

Целевая переменная в задаче классификации – класс, к которому принадлежит наблюдение.

Основные термины

- $\mathbb{X} = \mathbb{R}^d$ – пространство объектов
- $\mathbb{Y} = \{+1, -1\}$ – множество допустимых ответов
- « + 1 » – положительный класс
- « - 1 » – отрицательный класс

Линейная модель

$$a(x) = w_0 + \sum_{j=1}^d w_j x_j$$

Параметры линейной регрессии – веса (коэффициенты w_j). Вес w_0 называется свободным коэффициентом или сдвигом (bias). Заметим, что после знака суммы написано скалярное произведение. Также добавим в выборку w_{d+1} признак, равный единице, тогда необходимость в свободном коэффициенте отпадет. Перепишем формулу в более компактном виде:

$$a(x) = \langle w, x \rangle$$


Линейный классификатор

$$a(x) = \langle w, x \rangle$$

Что можем сделать, чтобы стало -1 или +1? Взять знак!

$$a(x) = \text{sign} \langle w, x \rangle$$


Напоминание



$$sgn(x) = \begin{cases} 1 & \text{if } x > 0, \\ 0 & \text{if } x = 0, \\ -1 & \text{if } x < 0 \end{cases}$$

Геометрическая интерпретация

Уравнение вида $\langle w, x \rangle = 0$ определяет гиперплоскость (прямая на картинке).



- Если $\sum_{j=1}^n w_j x_j > 0$, то $\text{sign}(\sum_{j=1}^n w_j x_j) = +1$ – объект будет отнесен к положительному классу
- Если $\sum_{j=1}^n w_j x_j < 0$, то $\text{sign}(\sum_{j=1}^n w_j x_j) = -1$ – объект будет отнесен к отрицательному классу

Обучение линейного классификатора

Возьмем функционал качества error rate:

$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} [a(x_i) \neq y_i]$$

Его будем минимизировать:

$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} [a(x_i) \neq y_i] = \frac{1}{\ell} \sum_{i=1}^{\ell} [\text{sign} \langle w, x_i \rangle \neq y_i] \rightarrow \min_w$$

Обучение линейного классификатора

- Функционал дискретный
- Не можем минимизировать градиентными методами или вывести аналитическое решение
- Попробуем перейти к минимизации гладкого функционала

Обучение линейного классификатора


Перепишем наш функционал:

$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} [y_i \underbrace{\langle w, x_i \rangle}_{M_i} < 0] \rightarrow \min_w$$

- $M = y \langle w, x \rangle$ – Отступ
- $M > 0$ – целевая переменная и скалярное произведение одного знака, значит, класс правильно предсказан
- $M < 0$ – целевая переменная и скалярное произведение не одного знака, значит, класс неверно предсказан


Обучение линейного классификатора

- Абсолютная величина отступа $|M|$ – по сути, расстояние до разделяющей гиперплоскости
- Абсолютная величина отступа отражает уверенность прогноза



Обучение линейного классификатора

Ранжирование объектов по возрастанию отступа:




Обучение линейного классификатора

- Если отступ очень большой и отрицательный – модель ошиблась, но очень уверена в своем прогнозе
- Зачастую это выброс

Обучение линейного классификатора

$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} \underbrace{[y_i \langle w, x_i \rangle < 0]}_{M_i}$$

Данный функционал оценивает ошибку алгоритма с помощью функции потерь $L(M) = [M < 0]$




Обучение линейного классификатора

$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} \underbrace{[y_i \langle w, x_i \rangle < 0]}_{M_i}$$

Данный функционал оценивает ошибку алгоритма с помощью функции потерь $L(M) = [M < 0]$

Хотим гладкий функционал – оценим эту функцию сверху:

$$L(M) \leq \tilde{L}(M)$$



Обучение линейного классификатора

➤ После этого можно получить верхнюю оценку на функционал:

$$Q(a, X) \leq \frac{1}{\ell} \sum_{i=1}^{\ell} \tilde{L}(y_i \langle w, x_i \rangle) \rightarrow \min_w$$

Обучение линейного классификатора

➤ $\tilde{L}(M)$ выберем гладкой и будем оптимизировать

$$0 \leq \frac{1}{l} \sum_{i=1}^l [y_i < w_i x_i > < 0] \leq \frac{1}{l} \sum_{i=1}^l \tilde{L}(y_i < w_i x_i >) \rightarrow \min_w$$

➤ Теперь верхнюю оценку можно будет минимизировать с помощью, например, градиентного спуска

➤ Если верхнюю оценку удастся приблизить к нулю, то и доля неправильных ответов тоже будет близка к нулю

Обучение линейного классификатора

Несколько примеров:

1. $\tilde{L}(M) = \log(1 + e^{-M})$ — логистическая функция потерь **L**
2. $\tilde{L}(M) = (1 - M)_+ = \max(0, 1 - M)$ — кусочно-линейная функция потерь (используется в методе опорных векторов) **V**
3. $\tilde{L}(M) = (-M)_+ = \max(0, -M)$ — кусочно-линейная функция потерь (соответствует персептрону Розенблатта) **H**
4. $\tilde{L}(M) = e^{-M}$ — экспоненциальная функция потерь **E**
5. $\tilde{L}(M) = 2/(1 + e^M)$ — сигмоидная функция потерь **S**

Обучение линейного классификатора

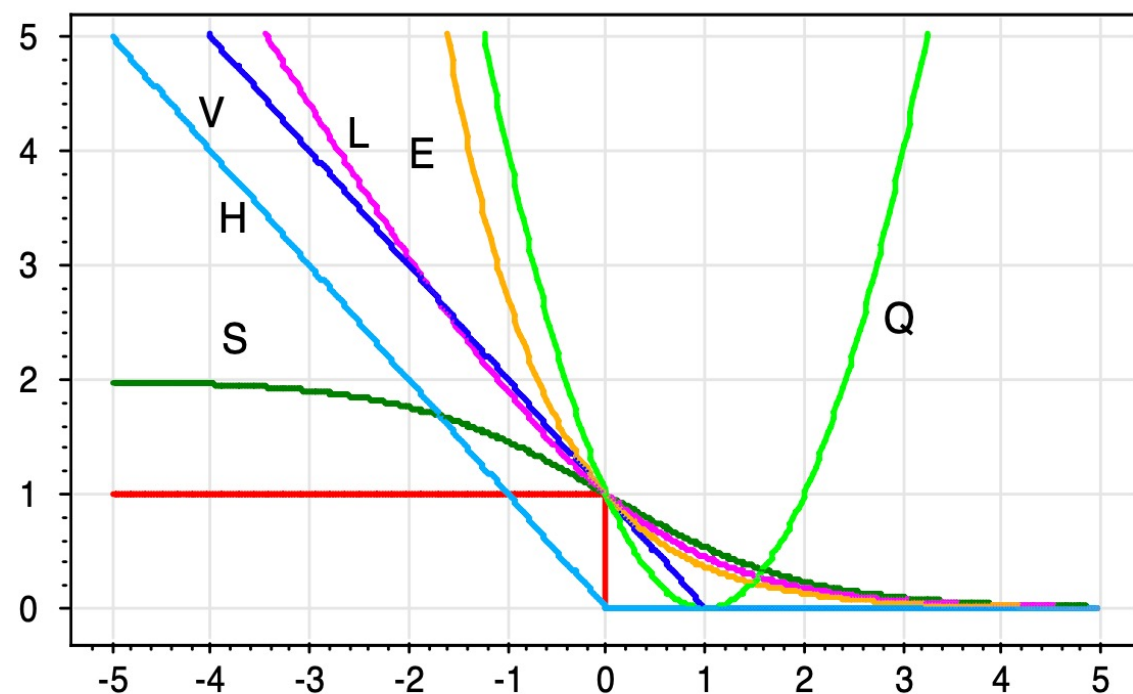


Рис. 1. Верхние оценки на пороговую функцию потерь.

Метрики качества

Метрики качества

➤ Аксирасу – доля правильных ответов

$$\text{accuracy}(a, x) = \frac{1}{\ell} \sum_{i=1}^{\ell} [a(x_i) = y_i].$$

99.5% — 0
0.5% — 1

$y = 0$

acc = 99.5% = 0.995

Метрики качества

a_1 и a_2

a_1 и $a_2, a_2 > a_1$

a_1

a_2

$a_1 - a_2$

$\frac{a_1 - a_2}{r}$

20%

10%

10%

50

50%

25%

25%

5

0.1%

0.01%

0.09%

9

Метрики качества

➤ Матрица ошибок (confusion matrix):

| | $y = 1$ | $y = -1$ |
|-------------|---------------------|---------------------|
| $a(x) = 1$ | True Positive (TP) | False Positive (FP) |
| $a(x) = -1$ | False negative (FN) | True Negative (TN) |

Метрики качества

➤ Перепишем в контексте матрицы ошибок (confusion matrix):

$$\text{accuracy} = \frac{TP + TN}{TP + FP + FN + TN}$$

Метрики качества

➤ Точность (precision) и полнота (recall):

$$\text{precision} = \frac{TP}{TP + FP};$$
$$\text{recall} = \frac{TP}{TP + FN}.$$

Метрики качества

H_1 : есть беременность; H_0 : нет беременности

Истинный
позитив, верна
 H_1




Ложный
позитив,
ошибка I
рода,
ложная
тревога

Ложный
негатив,
ошибка II рода,
халатная
беспечность



Истинный
негатив,
верна H_0

Точность и полнота



Метрики качества

➤ F-мера:

$$F = \frac{2 * \text{precision} * \text{recall}}{\text{precision} + \text{recall}}$$

Метрики качества

- Для задач, связанных с выбором подмножества (выделение лояльных клиентов банка, например) можно использовать прирост концентрации (lift). Если при рассылке предложений о кредите клиентам из подмножества и всем клиентам будет получаться одна и та же доля откликнувшихся, то подмножество не будет представлять особой ценности.

$$\text{lift} = \frac{\text{precision}}{(\text{TP} + \text{FN})/\ell}$$


- Улучшение доли положительных объектов в данном подмножестве относительно доли в случайно выбранном подмножестве такого же размера.

Метрики качества

➤ ROC-AUC (Area under receiver operating characteristic):

$$\text{FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}};$$

$$\text{TPR} = \frac{\text{TP}}{\text{TP} + \text{FN}}.$$



Метрики качества

➤ Индекс Джини:


$$\text{FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}};$$

$$\text{TPR} = \frac{\text{TP}}{\text{TP} + \text{FN}}.$$

$$\text{Gini} = 2\text{AUC} - 1.$$


➤ Это площадь между ROC-кривой и диагональю, соединяющей точки (0,0) и (1,1).

Крутая статья про Gini: [URL](#)



Задачи

2.5 0.05 2/3 1
 2.6 0 1 1



Пример построения ROC-кривой

| $b(x)$ | 0.2 | 0.4 | 0.1 | 0.7 | 0.05 |
|--------|-----|-----|-----|-----|------|
| y | -1 | +1 | -1 | +1 | +1 |

2) $b(x)$ y
 0.7 +1

 0.4 +1

 0.2 -1


 0.1 -1

 0.05 +1

2.1 $t = 0.7$ $a(x) \leq b(x) > t$
 $TPR = \frac{0}{0+3} = 0$ $FPR = 0$
 2.2 $t = 0.4$; $\frac{1}{1+2} = \frac{1}{3} \therefore 0$
 2.3 $t = 0.2$ $\frac{2}{2+1} = \frac{2}{3} \therefore 0$
 2.4 $t = 0.1$ $\frac{2}{3}; \frac{1}{2}$

Пример построения ROC-кривой

| y_i | \hat{p}_i | |
|-------|-------------|---|
| 1 | 0.7 | 0 |
| 0 | 0.3 | 0 |
| 1 | 0.25 | 0 |
| 0 | 0.2 | 0 |
| 0 | 0.1 | 0 |



$$P_r = \frac{TP}{TP + FP}$$

$$Rec = \frac{TP}{TP + FN}$$

Пример построения PR-кривой

| $\geq t$ | R | R_{ec} |
|----------|---------------|----------|
| 0.1 | $\frac{2}{5}$ | 1 |
| 0.2 | $\frac{1}{2}$ | 1 |
| 0.25 | $\frac{2}{3}$ | 1 |
| 0.3 | 0.5 | 0.5 |
| 0.7 | 1 | 0.5 |
| 0.8 | 0 | 0 |

$$Pr = \frac{1}{TP + FP}$$

$$R_{ec} = \frac{TP}{TP + FN}$$

